Juan Manuel Arias Gutiérrez – 000511986

Juan Andrés Ciro Boada – 000511559

Chat con IA

La IA que se uso como herramienta para el desarrollo de este trabajo fue Claude. A continuación, están los pantallazos de toda la interacción con la herramienta:

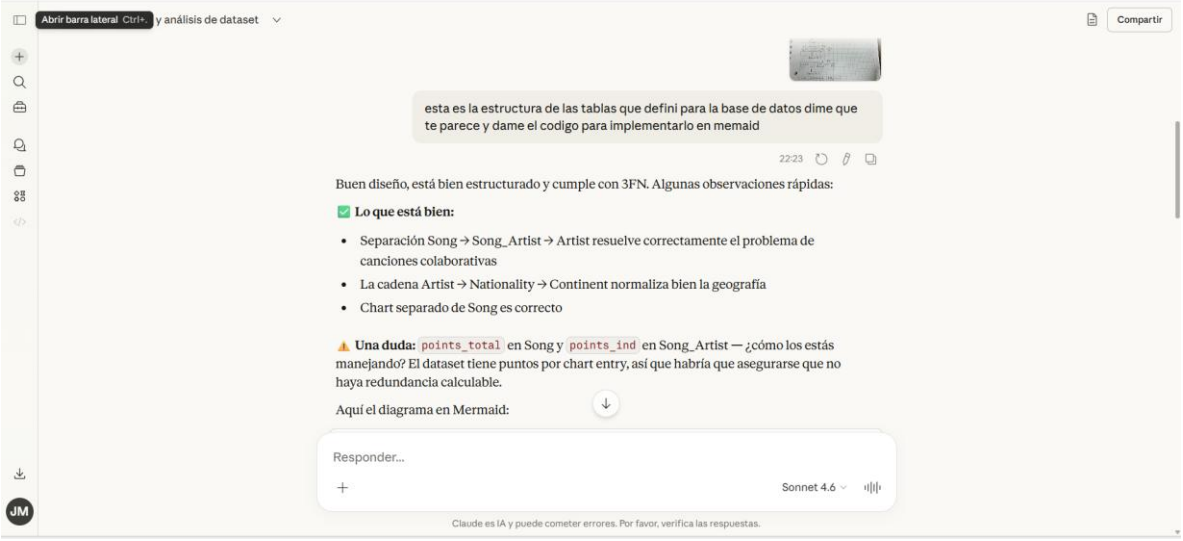

Abrir barra lateral Ctrl+. y análisis de dataset

Compartir

TXT

es que unos son los puntos de la cancion y los otros son los que tiene el artista individualmente en la cancion

Entendido, tiene sentido. Entonces:

- `points_total` **en Song** → puntos acumulados de la canción en total
- `points_ind` **en Song_Artist** → puntos que le corresponden a cada artista de esa canción

Solo ten en cuenta que si `points_total` es la suma de `points_ind` de todos los artistas, sería un dato **derivado/calculable**, lo cual técnicamente viola 3FN.

¿Cómo están definidos exactamente en el dataset? ¿Son columnas independientes o uno se calcula del otro? Así confirmamos si tiene sentido mantener ambos o si `points_total` debería ser una vista/campo calculado.

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica las respuestas.

Claude

Nuevo chat
Buscar
Personalizar

Chats
Proyectos
Artefactos
Código Actualizar

Destacados
Ayuda con examen y análisis de ...

Recientes
Refactoring de arquitectura a SOA
Modelo de datos 3FN con análisi...
Diagrama de Gantt del proyecto
Diagrama de Gantt para proyecto
Organigrama del proyecto en W...
Sistema de votación electrónica ...
Calculadora RPC con HTTP en P...

Juan Manuel

Ayuda con examen y análisis de dataset

Compartir

PK_FK	int
artist_id	PK_FK
numeric	points_ind
smallint	artist_order

se esta viendo mal esta tabla en el diagrama por alguna razon, arreglalo

El problema es que las columnas del tipo de dato y el nombre están invertidas/desalineadas en el Mermaid. Corrígelo así:

mermaid

```
erDiagram
    CONTINENT {
        int continent_id PK
        varchar continent_name UK
    }

    NATIONALITY {
        int nationality_id PK
        varchar nationality_name UK
        int continent_id FK
    }
```

Responder...

Sonnet 4.6

Ayuda con examen y análisis de dataset

Compartir

Script_Creacion_Base_de_Datos

voy a crear mi base de datos en postgres usando NEON este es mi script para la creacion de la base de datos y los usuarios, esta correcto?

Déjame leer el archivo primero.

Reading the database creation script >

El script está muy bien estructurado. Algunas observaciones:

✅ **Lo que está bien:**

- Separación de roles: `spotify_app` para crear el modelo y `spotify_usr` para operaciones de la app
- Privilegios mínimos correctamente asignados
- `search_path` configurado para ambos u[illegible]os
- `alter default privileges` para objetos futuros — muy importante y frecuentemente

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Abrir barra lateral Ctrl+. y análisis de dataset

Compartir

- `alter default privileges` para objetos futuros — muy importante y frecuentemente olvidado
- Extensión UUID incluida

⚠️ **Consideraciones para Neon específicamente:**

- En Neon **no puedes crear una nueva database** con `CREATE DATABASE` desde el script — la base de datos se crea desde el dashboard de Neon. Deberías eliminar la línea 16 y el `\c spotify_db` de la línea 19
- El comando `\c` es un metacomando de `psql`, no funciona en el editor SQL de Neon ni en la mayoría de IDEs — también puedes quitarlo
- En Neon el usuario `postgres` tiene limitaciones, es posible que `CREATE USER` funcione pero con restricciones dependiendo del plan

💡 **Sugerencia menor:**

- Las dos contraseñas son iguales (`unaClav3`). Para el entregable del examen no es crítico, pero es buena práctica diferenciarlas

¿Quieres que ajuste el script con esas correcciones para Neon?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Abrir barra lateral Ctrl+. y análisis de dataset

Compartir

Script_Creacion_Base_de_Datos

cambie algunas cosas por errores de neon para que lo tengas en cuenta para mas adelante, asi quedo

Reading updated script

Perfecto, ya lo tengo. Los cambios que hiciste tienen sentido para Neon:

- ✅ Eliminaste `CREATE DATABASE` y `\c` — correcto
- ✅ Referenciás directamente `neondb` que es la base de datos por defecto de Neon
- ✅ Las contraseñas ahora son diferentes para cada usuario

Queda guardado en contexto. Dime cuando quieras continuar con el siguiente paso. 😀

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Abrir barra lateral Ctrl+. y análisis de dataset

Compartir

cambie un poco el esquema porque la cancion no siempre tiene los mismos puntos sino que depende del rank entonces quedo asi:

```
erDiagram
    CONTINENT {
        int continent_id PK
        varchar continent_name UK
    }
```

Mostrar más

Tiene mucho más sentido así. Los puntos dependen del ranking en cada entrada del chart, no de la canción en sí.

✅ **El cambio es correcto porque:**

- `points_total` ahora vive en `CHART` donde sí tiene sentido — cada vez que una canción aparece en el chart tiene un rank y por ende unos puntos diferentes
- `SONG` queda solo con los atributos intrínsecos de la canción (características de audio, URL, etc.)

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

⚠️ **Una observación:** ahora `points_ind` en `SONG_ARTIST` — ¿cómo se va a calcular? Porque si los puntos totales están en `CHART`, los puntos individuales del artista deberían derivarse de ahí también. ¿Lo estás pensando como un campo que se llena al momento de insertar, o lo eliminarías también de `SONG_ARTIST`?

Dime para tenerlo claro antes de generar el SQL de creación de tablas.

Script_Creacion_modelo.sql
122 líneas
SQL

finalmente este asi quedo mi diagrama, y este es el script que tengo de sql, revisa si te parece que esta bien hecho

```
erDiagram
    CONTINENT {
        int continent_id PK
        varchar continent_name UK
    }
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

El script está muy bien hecho. Observaciones:

✅ **Lo que está excelente:**

- Nomenclatura consistente en snake_case
- Constraints nombradas explícitamente (`nationality_continent_fk`, `chart_unique_song_date`, etc.) — muy buena práctica
- `ON DELETE CASCADE` en `SONG_ARTIST` y `CHART` tiene sentido
- Checks en `CHART` para rank y points
- Índices bien pensados para las columnas más consultadas
- `UNIQUE (song_id, chart_date)` en CHART evita duplicados de una canción en la misma fecha

⚠️ **Detalles menores a revisar:**

1. `song_url` — en el diagrama está como `UK` (unique) pero en el script no tiene `unique`. ¿Lo quieres agregar?
2. `points_ind` en `SONG_ARTIST` — sigue pendiente la pregunta de antes: ¿cómo se va a poblar ese campo? Porque los puntos totales están en `CHART`, no en `SONG_ARTIST`. Si no lo vas a usar, considera eliminarlo para no violar 3FN.

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

¿Quieres corregir esos detalles antes de pasar al script de carga de datos?

Script_Creacion_modelo.sql
125 líneas
SQL

Asi quedo con los cambios que sugeriste, el campo points_id se encuentra tambien en los datos proporcionados entonces no hay problema con eso

Perfecto, el script quedó muy bien. Ya lo tengo actualizado en contexto.

Resumiendo el estado final:

- ✅ `song_url` con `not null unique`
- ✅ Índice compuesto `idx_chart_date_rank` agregado
- ✅ `points_ind` justificado por el dataset

Listo para el siguiente paso, dime qué sigue. 😄

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

ayudame a crear la tabla temporal para añadir los datos teniendo en cuenta que este es el orden de las columnas del dataset:

Rank;Title;Artists;Date;Danceability;Energy;Loudness;Speechiness;Acousticness;Instrumentalness;Valence;# of Artist;Artist (Ind.);# of Nationality;Nationality;Continent;Points (Total);Points (Ind for each Artist/Nat);id;Song URL

Aquí está la tabla temporal que mapea exactamente las columnas del CSV:

```sql
-- ============================================
-- ESQUEMA INICIAL: Tabla temporal con datos crudos
-- ============================================

create schema if not exists initial;

create table initial.spotify_raw (
    rank                int,
    title               varchar(200),
    artists             varchar(500),
    date                date,
    danceability        numeric,
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Notas importantes:

- Usa `varchar(500)` en `artists` porque pueden ser varios artistas separados por coma en colaboraciones
- `artist_ind` es el artista individual de esa fila (recuerda que la fila se repite por artista en colaboraciones)
- El separador del CSV es `;` — tenlo en cuenta al momento de hacer el `COPY` o la importación en Neon

¿Quieres también el comando `COPY` para cargar el CSV, o seguimos con el script de migración de `initial` a `core`?

es necesario crear el esquema initial? por que no se hace directamente en el esquema core?

Sí es necesario, y es parte del enunciado. El profesor pide explícitamente dos esquemas:

- `initial` → datos crudos, sin normalizar, tal como vienen del CSV (una tabla plana con todo)

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

- `initial` → datos crudos, sin normalizar, tal como vienen del CSV (una tabla plana con todo)
- `core` → datos normalizados en 3FN con todo el modelo que ya diseñaste

Esto es para poder comparar el plan de ejecución de consultas entre ambos esquemas y evidenciar la mejora en desempeño, que es precisamente el objetivo del examen.

Entonces el flujo sería:

1. Cargar CSV → `initial.spotify_raw`
2. Migrar y normalizar datos → tablas en `core`
3. Ejecutar consultas en ambos esquemas y comparar planes de ejecución

¿Continuamos con el script de migración de `initial` a `core`?

teniendo los datos en un esquema los puedo pasar facilmente a las tablas de otro?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Sí, en PostgreSQL es muy sencillo. Puedes usar `INSERT INTO ... SELECT FROM` entre esquemas sin problema. Por ejemplo:

```sql
-- Poblar CONTINENT
INSERT INTO core.continent (continent_name)
SELECT DISTINCT continent
FROM initial.spotify_raw
WHERE continent IS NOT NULL;
```

```sql
-- Poblar NATIONALITY
INSERT INTO core.nationality (nationality_name, continent_id)
SELECT DISTINCT
    sr.nationality,
    c.continent_id
FROM initial.spotify_raw sr
JOIN core.continent c ON c.continent_name = sr.continent
WHERE sr.nationality IS NOT NULL;
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Y así sucesivamente con el resto de tablas. PostgreSQL permite referenciar tablas de diferentes esquemas en la misma query simplemente usando `esquema.tabla`.

El orden de inserción importa por las FK:

1. `continent`
2. `nationality`
3. `artist`
4. `song`
5. `song_artist`
6. `chart`

¿Quieres que genere el script completo de migración para todas las tablas?

Responder...

Sonnet 4.6

Ayuda con examen y análisis de dataset

Compartir

ya ejecute el script exitosamente, por que no me sale el esquema en datagrip si ya actualice

Es un problema común de refresco en DataGrip. Prueba estas opciones:

1. **Clic derecho sobre** `neondb` → `Refresh` (o `Reload`)
2. Si no aparece, **clic derecho sobre** `neondb` → `Database Tools` → `Synchronize`
3. Si aún no aparece, puede ser que DataGrip no esté mostrando todos los esquemas. Ve a:
   - Clic en el ícono de ajustes/filtro del Database Explorer → `Schema` → asegúrate de que `core` e `initial` estén marcados como visibles

Lo más probable es la opción 3, ya que DataGrip a veces oculta esquemas que no estaban presentes cuando se configuró la conexión inicialmente. ¿Cuál de las opciones funcionó?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

El problema es que creaste el esquema `initial` con el usuario `postgres` pero no le diste permisos sobre él a `spotify_app` ni `spotify_usr`. Ejecuta esto con el usuario `postgres`:

```sql
-- Permisos sobre el esquema initial
GRANT CREATE, USAGE ON SCHEMA initial TO spotify_app;
GRANT USAGE ON SCHEMA initial TO spotify_usr;

-- Permisos sobre objetos futuros en initial para spotify_usr
ALTER DEFAULT PRIVILEGES IN SCHEMA initial
    GRANT SELECT, INSERT, UPDATE, DELETE ON TABLES TO spotify_usr;

ALTER DEFAULT PRIVILEGES IN SCHEMA initial
    GRANT EXECUTE ON ROUTINES TO spotify_usr;
```

¿Con qué usuario estás conectado en DataGrip actualmente?

dale a spotify_app y spotify_ s mismos permisos que les dimos a los del esquema core

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

dale a spotify_app y spotify_usr los mismos permisos que les dimos a los del esquema core

```sql
-- Permisos sobre el esquema initial para spotify_app
GRANT CREATE, USAGE ON SCHEMA initial TO spotify_app;
ALTER USER spotify_app SET search_path TO core, initial;

-- Permisos sobre el esquema initial para spotify_usr
GRANT USAGE ON SCHEMA initial TO spotify_usr;

-- Privilegios sobre tablas existentes
GRANT SELECT, INSERT, UPDATE, DELETE, TRIGGER ON ALL TABLES IN SCHEMA initial TO spo

-- Privilegios sobre secuencias existentes
GRANT USAGE, SELECT ON ALL SEQUENCES IN SCHEMA initial TO spotify_usr;

-- Privilegios sobre funciones existentes
GRANT EXECUTE ON ALL FUNCTIONS IN SCHEMA initial TO spotify_usr;

-- Privilegios sobre procedimientos existentes
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

añade eso tambien en el script

¿A cuál de los dos scripts te refieres — al de creación de base de datos y usuarios, o al de creación del modelo?

me referia a que añadieras al ultimo script que me diste la actualizacion del search_path

Aquí está el script completo actualizado:

```sql
-- Permisos sobre el esquema initial para spotify_app
GRANT CREATE, USAGE ON SCHEMA initial TO spotify_app;

-- Permisos sobre el esquema initial pa potify_usr
GRANT USAGE ON SCHEMA initial TO spotify_usr;
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

tuve estos errores con las fechas al intentar subir los datos, como puedo solucionarlo

El problema es que las fechas en el CSV están en formato `DD/MM/YYYY` pero PostgreSQL espera `YYYY-MM-DD` por defecto.

Tienes dos opciones:

Opción 1 (más fácil) — cambiar el campo a `varchar` en la tabla raw y convertir al migrar a `core`:

```sql
-- En initial.spotify_raw cambia date a varchar
ALTER TABLE initial.spotify_raw ALTER COLUMN date TYPE varchar(20);
```

Opción 2 — decirle a PostgreSQL el formato al importar:

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Opción 2 — decirle a PostgreSQL el formato al importar:

```sql
-- Antes de hacer el COPY o importación
SET datestyle = 'DMY';
```

Te recomiendo la **Opción 2** porque es más simple — solo ejecuta ese `SET` antes de cargar los datos y PostgreSQL interpretará las fechas como `DD/MM/YYYY` correctamente.

¿Cómo estás cargando el CSV, con `COPY` o con el importador de DataGrip?

lo estaba cargando con el importador de datagrip

Entonces en DataGrip el `SET datestyle` no aplica directamente. La forma más fácil es:

Opción 1 — Cambiar el campo a `varchar` en la tabla raw:

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Opción 1 — Cambiar el campo a `varchar` en la tabla raw:

```sql
ALTER TABLE initial.spotify_raw ALTER COLUMN date TYPE varchar(20);
```

Así carga sin problema y luego al migrar a `core` conviertes con:

```sql
TO_DATE(sr.date, 'DD/MM/YYYY')
```

Opción 2 — Desde el importador de DataGrip:

- Abre el importador nuevamente
- Busca la columna `date` en el mapeo de columnas
- Cambia el formato de fecha a `dd/MM/yyyy`

Te recomiendo la **Opción 1** porque es la más limpia para una tabla de datos crudos — total, `initial.spotify_raw` no necesita validación de tipos, ese es precisamente el punto de tenerla como tabla temporal sin normalizar.

¿Cuál prefieres?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

ahora tengo este

El problema es que la columna `# of Artist` en el CSV tiene el encabezado `"Artist 1"`, `"Artist 2"` etc. en lugar de un número — parece que DataGrip está mapeando mal las columnas.

La solución más simple es la misma — cambiar `num_artists` y `num_nationality` a `varchar` en la tabla raw:

```sql
ALTER TABLE initial.spotify_raw ALTER COLUMN num_artists TYPE varchar(50);
ALTER TABLE initial.spotify_raw ALTER COLUMN num_nationality TYPE varchar(50);
```

Recuerda que en `initial.spotify_raw` no necesitamos tipos estrictos, eso se maneja al migrar a `core`. Lo importante es que los dato ren sin error.

Luego de hacer esos ALTER, intenta cargar el CSV nuevamente. ¿También sigue teniendo

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

se puede manejar facilmente esto al migrar a core?

Sí, totalmente. Al migrar a `core` simplemente ignoras esas columnas — `num_artists` y `num_nationality` son datos que se pueden **derivar** de los datos que ya tienes normalizados.

Por ejemplo:

- `num_artists` → se puede obtener contando los registros en `song_artist` para esa canción
- `num_nationality` → igual, contando las nacionalidades distintas de los artistas de esa canción

Así que en el script de migración simplemente no las usas y listo. Son columnas informativas del CSV que no necesitas insertar en ninguna tabla de `core`.

¿Hacemos los ALTER y continuamos con la carga?

explicame bien como se haria esto

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

explicame bien como se haria esto

Al migrar los datos de `initial.spotify_raw` a las tablas de `core`, el proceso sería así para cada tabla:

1. CONTINENT — simple, tomas los valores distintos:

```sql
INSERT INTO core.continent (continent_name)
SELECT DISTINCT continent
FROM initial.spotify_raw
WHERE continent IS NOT NULL;
```

2. NATIONALITY — igual, valores distintos con su continente:

```sql
INSERT INTO core.nationality (nationality_name, continent_id)
SELECT DISTINCT sr.nationality, c.continent_id
FROM initial.spotify_raw sr
JOIN core.continent c ON c.continent_name = sr.continent
WHERE sr.nationality IS NOT NULL;
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

2. NATIONALITY — igual, valores distintos con su continente:

```sql
INSERT INTO core.nationality (nationality_name, continent_id)
SELECT DISTINCT sr.nationality, c.continent_id
FROM initial.spotify_raw sr
JOIN core.continent c ON c.continent_name = sr.continent
WHERE sr.nationality IS NOT NULL;
```

3. ARTIST — aquí usas `artist_ind` que es el artista individual por fila:

```sql
INSERT INTO core.artist (artist_name, nationality_id)
SELECT DISTINCT sr.artist_ind, n.nationality_id
FROM initial.spotify_raw sr
JOIN core.nationality n ON n.nationality_name = sr.nationality
WHERE sr.artist_ind IS NOT NULL;
```

4. SONG — una fila por `spotify_id` único:

```sql
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

```sql
    s.song_id, sr.rank, TO_DATE(sr.date, 'DD/MM/YYYY'), sr.points_total
FROM initial.spotify_raw sr
JOIN core.song s ON s.spotify_id = sr.spotify_id;
```

6. SONG_ARTIST — aquí no necesitas `num_artists` ni `num_nationality` para nada, usas directamente `artist_ind`:

```sql
INSERT INTO core.song_artist (song_id, artist_id, points_ind, artist_order)
SELECT DISTINCT
    s.song_id,
    a.artist_id,
    sr.points_ind,
    ROW_NUMBER() OVER (PARTITION BY sr.spotify_id ORDER BY sr.artist_ind) AS artist_
FROM initial.spotify_raw sr
JOIN core.song s ON s.spotify_id = sr.spotify_id
JOIN core.artist a ON a.artist_name = sr.artist_ind;
```

Como ves, `num_artists` y `num_nationality` nunca se usan — la normalización los hace innecesarios porque esa información queda implícita en las relaciones entre tablas. ¿Quieres que ajustemos algo antes de ejecuta

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

El error ocurre porque un mismo artista aparece con **diferentes nacionalidades** en el dataset, entonces el `DISTINCT` no lo elimina porque la combinación `(artist_ind, nationality)` es diferente, pero el `artist_name` se repite violando el `UNIQUE`.

Solución — tomar solo la primera nacionalidad que aparezca para cada artista:

```sql
INSERT INTO core.artist (artist_name, nationality_id)
SELECT DISTINCT ON (sr.artist_ind)
    sr.artist_ind,
    n.nationality_id
FROM initial.spotify_raw sr
JOIN core.nationality n ON n.nationality_name = sr.nationality
WHERE sr.artist_ind IS NOT NULL
ORDER BY sr.artist_ind;
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

El mismo problema — hay combinaciones duplicadas de `(song_id, artist_id)` en el raw. Usa `DISTINCT ON` igual que antes:

```sql
INSERT INTO core.song_artist (song_id, artist_id, points_ind, artist_order)
SELECT DISTINCT ON (s.song_id, a.artist_id)
    s.song_id,
    a.artist_id,
    sr.points_ind,
    ROW_NUMBER() OVER (PARTITION BY sr.spotify_id ORDER BY sr.artist_ind) AS artist_
FROM initial.spotify_raw sr
JOIN core.song s ON s.spotify_id = sr.spotify_id
JOIN core.artist a ON a.artist_name = sr.artist_ind
ORDER BY s.song_id, a.artist_id;
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

ahora dame un script completo con la migracion de todos los datos

Aquí está el script completo de migración:

```sql
-- ============================================
-- MIGRACIÓN DE DATOS: initial -> core
-- Scripts Examen #2
-- Curso de Tópicos Avanzados de base de datos - UPB 202610
-- Juan Manuel Arias - 000511985
-- Juan Andrés Ciro - 000511559
-- ============================================

SET search_path TO core, initial;

-- ============================================
-- 1. CONTINENT
-- ============================================
INSERT INTO core.continent (continent_name)
SELECT DISTINCT continent
FROM initial.spotify_raw
WHERE continent IS NOT NULL;
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

```sql
-- 6. SONG_ARTIST
-- ==========================================
INSERT INTO core.song_artist (song_id, artist_id, points_ind, artist_order)
SELECT DISTINCT ON (s.song_id, a.artist_id)
    s.song_id,
    a.artist_id,
    sr.points_ind,
    ROW_NUMBER() OVER (PARTITION BY sr.spotify_id ORDER BY sr.artist_ind) AS artist_
FROM initial.spotify_raw sr
JOIN core.song s ON s.spotify_id = sr.spotify_id
JOIN core.artist a ON a.artist_name = sr.artist_ind
ORDER BY s.song_id, a.artist_id;
```

El orden es importante — respeta las dependencias de FK. Si alguna inserción falla dime el error y lo corregimos. ¿Lo ejecutamos paso a paso o todo junto?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

SQL

explicame paso a paso como hacer esto:

A esta consulta, genere el plan de ejecución donde se evidencie el árbol de las acciones que realizó la base de datos para resolver la petición. Acompañe este plan con una explicación sobre la operación que considera la más costosa, por qué, y cómo el diseño del modelo o los índices creados influyen en ese costo,

22:41

Te explico paso a paso:

Paso 1 — Generar el plan de ejecución en Neon

Ejecuta esto en Neon (no en DataGrip, porque Neon tiene un visualizador mejor):

```sql
EXPLAIN ANALYZE
WITH artist_weekly_rank AS (
    -- ... toda la consulta igual
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Ejecuta esto en Neon (no en DataGrip, porque Neon tiene un visualizador mejor):

```sql
EXPLAIN ANALYZE
WITH artist_weekly_rank AS (
    -- ... toda la consulta igual
);
```

Simplemente agrega `EXPLAIN ANALYZE` antes del `WITH`.

Paso 2 — Interpretar el árbol

El resultado se verá algo así:

```
Gather Merge  (cost=... rows=...)
  -> Sort (cost=...)
      -> Hash Join (cost=...)
          -> WindowAgg (cost=...)
              -> Hash Join (cost=...)
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Lo que debes capturar en el PDF:

- **Todo el árbol** — captura de pantalla completa
- **Las filas afectadas** de cada nodo
- **El costo** de cada operación (el número después de `cost=`)

Paso 3 — Identificar la operación más costosa

Busca el nodo con el **costo más alto**. En esta consulta probablemente será uno de estos:

- `WindowAgg` — porque aplica `LAG()` y `SUM() OVER()` sobre todos los registros particionados por artista
- `Hash Join` entre `chart` y `song_artist` — porque cruza dos tablas grandes

Paso 4 — Redactar la explicación

Debes escribir un párrafo explicando:

1. **Cuál es la operación más costosa** — por ejemplo:

> *"La operación más costosa es el WindowAgg con un costo de X, porque debe*

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

> *chart_date para calcular LAG() y SUM() OVER()*

2. **Por qué es costosa:**

> *"Requiere ordenar y mantener en memoria todos los registros agrupados por artista antes de poder calcular la función de ventana"*

3. **Cómo el modelo y los índices influyen:**

> *"El índice `idx_chart_date_rank` reduce el costo del ordenamiento por fecha. El índice `idx_chart_song` acelera el JOIN entre chart y song_artist evitando un Seq Scan completo. Sin estos índices el motor haría Seq Scans sobre todas las tablas aumentando significativamente el costo"*

Paso 5 — Capturar evidencia para el PDF

En Neon después de ejecutar el `EXPLAIN ANALYZE` verás el árbol visual. Toma capturas donde se vea claramente:

- ✅ El árbol completo de operaciones
- ✅ Las filas afectadas por cada nodo
- ✅ El costo de cada operación
- ✅ Los resultados de la consulta (las filas que retorna)

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

puedo ejecutar todo el script completo despues del explain analyze?

22:45

Sí, exactamente así:

```sql
EXPLAIN ANALYZE
WITH artist_weekly_rank AS (
    SELECT
        a.artist_id,
        a.artist_name,
        c.chart_date,
        MIN(c.rank) AS best_rank,
        SUM(sa.points_ind) AS weekly_points
    FROM core.artist a
    JOIN core.song_artist sa ON sa.artist_id = a.artist_id
    JOIN core.chart c ON c.song_id = sa.song_id
    GROUP BY a.artist_id, a.artist_name, c.chart_date
),

artist_rank_evolution AS (
    SELECT
```

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

```
        MIN(chart_date) AS streak_start,
        MAX(chart_date) AS streak_end,
        MIN(best_rank) AS best_rank_in_streak
    FROM artist_streaks
    WHERE improved = 1
    GROUP BY artist_id, artist_name, streak_group
    HAVING COUNT(*) >= 2
)

SELECT
    artist_name,
    weeks_improving,
    total_points_in_streak,
    streak_start,
    streak_end,
    best_rank_in_streak
FROM streak_summary
ORDER BY weeks_improving DESC, total_points_in_streak DESC;
```

`EXPLAIN ANALYZE` se aplica a toda la consulta que le sigue, sin importar que tan larga sea. El motor la ejecuta completa y te devuelve tanto el plan de ejecución como los resultados reales.

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

y esto de todas formas realizara las consultas?

Sí, `EXPLAIN ANALYZE` **sí ejecuta** la consulta realmente — a diferencia de `EXPLAIN` solo que únicamente estima sin ejecutar.

Entonces obtendrás:

- ✅ El plan de ejecución con costos **reales**
- ✅ Las filas realmente procesadas
- ✅ Los tiempos reales de cada operación

Pero ojo — **no te mostrará los resultados de la consulta** (las filas que retorna el SELECT final), solo el plan.

Entonces para el PDF necesitas ejecutar **dos veces**:

1. `EXPLAIN ANALYZE + consulta` → para capturar el plan de ejecución
2. La consulta sola → para capturar los registros resultantes

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

hay alguna manera de exportar todo esto para poder ponerlo en mi archivo, en mi archivo debe salir tooda la informacion de cada parte del arbol

Sí, la mejor forma es usar la pestaña **"Raw"** que ves arriba en la misma pantalla. Ahí sale el texto completo del plan de ejecución con todos los detalles de cada nodo.

Pasos:

1. Haz clic en la pestaña **"Raw"**
2. Selecciona todo el texto (`Ctrl+A`)
3. Cópialo y pégalo en un archivo de texto

Para el PDF tienes dos opciones:

Opción 1 — Capturas del árbol visual:

- Haz zoom out en el navegador (`Ctrl+-`) hasta que quede todo el árbol visible
- Toma capturas de pantalla por secciones muy largo
- Las pegas en el PDF

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Opción 2 — Texto del Raw (más completo):

- Pegas el texto del Raw en el PDF con fuente monospace (Courier New)
- Tiene toda la información: costo, filas, tiempo de cada nodo

Te recomiendo **combinar ambas** — el árbol visual para que se vea bien, y el Raw completo como anexo para que el profesor pueda ver todos los detalles. ¿Quieres que te ayude a redactar la explicación de la operación más costosa basándome en lo que se ve en el árbol?

Sort (cost=133932.99..133935.54 rows=3321 width=63) (actual time=4155.025..4157.228 rows=41793 loops=1) Sort Key: streak_summary.weeks_improving ...

PASTED

estos fueron los resultados, ayudame ahora con con una explicación sobre la operación que considera la más costosa, por qué, y cómo el diseño del modelo o los índices creados influyen en ese costo

23:18

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

El índice `idx_chart_song` sobre `chart(song_id)` tuvo un impacto positivo claro: el motor usó un `Index Scan` en lugar de un `Seq Scan` sobre `chart`, ejecutándose `12,391 veces` (una por cada fila de `song_artist`) con un costo individual de solo `3.22` por iteración.

El índice `idx_chart_date_rank` sobre `chart(chart_date, rank)` no fue utilizado directamente en esta consulta porque el acceso a `chart` se hace por `song_id`, no por fecha. Sin embargo, beneficiaría consultas que filtren directamente por rango de fechas.

Un índice que mejoraría significativamente el rendimiento sería uno compuesto sobre `song_artist(artist_id, song_id)`, ya que eliminaría el `Seq Scan` sobre esa tabla y permitiría que el `Merge Join` con `artist` fuera más eficiente, reduciendo el costo del `Incremental Sort` subsiguiente.

¿Quieres que también redacte la explicación de la Etapa 3 (dominancia geográfica) una vez tengas ese plan de ejecución?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

s=13921 loops=1) Sort Key: cwp.chart_date, (rank() ...

PASTED

este fue el analisis de la otra consulta, ayudame tambien a explicarlo como el anterior

Basándome en el plan de ejecución, aquí está la explicación lista para el PDF:

Análisis del Plan de Ejecución — Etapa 3

Operación más costosa: GroupAggregate (continent_weekly_points)

La operación más costosa del plan es el `GroupAggregate` del CTE `continent_weekly_points`, con un costo estimado de `127,267.00` y un tiempo real de `2,285 ms` sobre `13,921 filas`. Esta operación agrupa los datos por `chart_date` y `continent_id` para sumar los puntos aportados por cada continente cada semana.

¿Por qué es la más costosa?

Esta operación es costosa por las siguientes razones:

En primer lugar, alimenta al `GroupAggregate` una cadena de cuatro `Nested Loops`

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

Análisis del Plan de Ejecución — Etapa 3

Operación más costosa: GroupAggregate (continent_weekly_points)

La operación más costosa del plan es el `GroupAggregate` del CTE `continent_weekly_points`, con un costo estimado de `127,267.00` y un tiempo real de `2,285 ms` sobre `13,921 filas`. Esta operación agrupa los datos por `chart_date` y `continent_id` para sumar los puntos aportados por cada continente cada semana.

¿Por qué es la más costosa?

Esta operación es costosa por las siguientes razones:

En primer lugar, alimenta al `GroupAggregate` una cadena de cuatro `Nested Loops` anidados que atraviesan las tablas `chart → song_artist → artist → nationality → continent`, produciendo `658,255 filas` antes de poder agruparse. Recorrer esta cadena completa de joins es inherentemente costoso porque multiplica las iteraciones en cada nivel.

En segundo lugar, para ejecutar el `GroupAggregate` los datos deben estar ordenados por `chart_date` y `continent_id`, lo que requiere un `Incremental Sort` que tomó `2,187 ms`. Aunque el sort incremental es más eficiente que uno completo, el volumen de filas hace que sea la operación más lenta del plan.

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.

Ayuda con examen y análisis de dataset

Compartir

habilitó el `Incremental Sort` posterior sin necesidad de reordenar desde cero.

El mecanismo de `Memoize` de PostgreSQL jugó un papel clave en el rendimiento: al atravesar los `Nested Loops`, el motor cacheó los resultados de los lookups repetidos sobre `song_artist`, `artist`, `nationality` y `continent`. Por ejemplo, de `465,979` accesos a `song_artist`, solo `9,160` fueron lecturas reales — las `456,819` restantes fueron hits de caché. Esto redujo drásticamente el costo real de los joins.

Un índice compuesto sobre `song_artist(song_id, artist_id)` mejoraría aún más el rendimiento, ya que el acceso actual usa `song_artist_pk` que es el índice de la clave primaria `(song_id, artist_id)` — lo cual ya es óptimo en este caso. Sin embargo, un índice sobre `artist(nationality_id)` evitaría el lookup por `artist_pkey` y permitiría al motor navegar directamente desde nacionalidad hacia artista sin pasar por el `Memoize`.

¿Quieres que ahora te ayude con el README o con algún otro entregable del examen?

Responder...

Sonnet 4.6

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.